



Campus Santa Fe

Actividad en Clase - Ante-proyecto bajo los principios del ML Ops

Inteligencia artificial avanzada para la ciencia de datos II (Gpo 101)

Andrés Jaramillo Barón - A01029079

Pedro Mauri Mtz - A01029143

Edoardo Bucheli Susarrey

01/10/2025

Descripción de proyecto:

Herramienta capaz de predecir el comportamiento futuro de activos financieros, utilizando datos históricos en conjunto con un análisis de sentimiento de noticias relacionadas; es decir, dos modelos de machine learning, uno que recibe y analiza el cambio en el valor de varios activos financieros, y otro que recibe y hace análisis sentimentales de noticias que afectan al activo analizado con el otro modelo. Con el objetivo de apoyar la toma de decisiones financieras de manera informada y basada en datos.

Elevator Pitch

Nuestro proyecto desarrolla una plataforma inteligente para el análisis y predicción del comportamiento futuro de activos financieros, integrando datos de precios, noticias y sentimiento de mercado en tiempo real. A través de un pipeline automatizado y basado en los principios de MLOps, garantizamos un sistema confiable, con datos validados y modelos reproducibles; escalable, capaz de procesar múltiples activos y fuentes simultáneamente; adaptable, ajustándose a los cambios del mercado y la aparición de nuevas señales; y mantenible, mediante versionamiento, monitoreo continuo y despliegue automatizado. En conjunto, la plataforma convierte grandes volúmenes de información financiera en predicciones accionables que respaldan decisiones más rápidas, precisas y basadas en evidencia.

Qué consideraciones se necesitan para ajustarse a los 4 principios de ML Ops.

1. Confiable:

Para que el sistema se construya para ofrecer predicciones confiables y verificables sobre el comportamiento futuro de los activos financieros. Cada pipeline debe incluir validaciones automáticas de calidad de datos y control de versiones para garantizar que los modelos siempre se entrenen con información precisa y actual. Además, los resultados se deben evaluar de forma continua con métricas de desempeño (especialmente precisión por el

daño que puede provocar un falso positivo), lo que permitirá monitorear y ajustar los modelos cuando la dinámica del mercado cambie. Esto asegura decisiones basadas en señales reales y no en sesgos de datos.

2. Escalable:

El pipeline debe estar diseñado para procesar grandes volúmenes de datos históricos y en tiempo real, provenientes de múltiples fuentes (valores de activos, noticias relacionadas). Aplicando una arquitectura modular y usando bases de datos relacionales optimizadas, puede escalar tanto en la cantidad de activos analizados como en la complejidad de los modelos predictivos. Esta capacidad permite aumentar el número de activos monitoreados y generar predicciones simultáneas sin degradar el rendimiento, manteniendo la agilidad del sistema incluso al crecer la demanda de información o el tamaño del portafolio.

3. Adaptable:

El sistema será altamente adaptable a la evolución de los mercados financieros. Los modelos se entrenan de manera continua con nuevos datos para ajustar sus predicciones ante cambios estructurales, eventos macroeconómicos o alteraciones en el sentimiento del mercado. Es decir que mientras más pase el tiempo, los modelos entrenando con los eventos sigan pasando a tiempo real mientras se corrige cuando una predicción fue errónea.

Por otra parte, la arquitectura desacoplada permite reemplazar o actualizar componentes por ejemplo, cambiar de un modelo estadístico a uno basado en aprendizaje profundo sin alterar el flujo general del pipeline. Esto garantiza que el sistema se mantenga vigente y efectivo frente a la volatilidad del entorno financiero.

4. Mantenable:

La mantenibilidad se logra mediante buenas prácticas de ingeniería y MLOps: control de versiones, documentación clara y pipelines automatizados de retraining y despliegue. Cada modelo, dataset y configuración está versionado, lo que facilita reproducir resultados y

resolver incidencias sin interrumpir la operación. Además, el monitoreo constante de métricas y logs permite detectar desajustes o degradaciones antes de que afecten las predicciones, manteniendo un sistema estable y fácil de evolucionar a largo plazo.

Conceptos teóricos a utilizar (Machine Learning clásico, Deep Learning, etc)

El proyecto se apoya en los fundamentos del Machine Learning y la Ciencia de Datos, centrados en la recolección, procesamiento y análisis de información para identificar patrones y realizar predicciones sobre el comportamiento de los activos financieros. Se emplean principios teóricos como la representación estructurada de datos, la extracción de características relevantes, la validación y evaluación de modelos, y la retroalimentación continua para mejorar el rendimiento del sistema. Además, se integran prácticas de MLOps que aseguran la automatización del ciclo de vida de los datos, la trazabilidad de los experimentos, la actualización constante de los pipelines y la escalabilidad de las soluciones.

Como parte del desarrollo, se realizó una investigación exploratoria sobre los modelos más utilizados en problemas de predicción financiera, tanto en series temporales como en análisis de texto. Entre los enfoques evaluados se encuentran modelos de Machine Learning clásico como Regresión Lineal, Árboles de Decisión, Random Forest, Gradient Boosting y Support Vector Machines (SVM), junto con técnicas más avanzadas de Deep Learning aplicadas a secuencias, como LSTM (Long Short-Term Memory), GRU (Gated Recurrent Units) y redes basadas en Transformers para el análisis de lenguaje natural y sentimiento en noticias financieras.

Para el momento en que se está realizando esta entrega, aún falta determinar cuál de estos modelos será implementado en la fase de desarrollo, considerando el equilibrio entre precisión, interpretabilidad, complejidad computacional y volumen de datos disponible.

En conjunto, estos conceptos teóricos proporcionan la base para construir un sistema robusto, reproducible y adaptable, capaz de transformar información financiera cruda como precios, noticias y tendencias en conocimiento útil para la toma de decisiones estratégicas.

Tecnologías a utilizar (frameworks, infraestructura, etc)

El proyecto se desarrollará principalmente en Python, por su versatilidad y amplio ecosistema para ciencia de datos y aprendizaje automático. Este lenguaje permitirá implementar tanto la ingesta y procesamiento de datos financieros y noticias, como los pipelines de entrenamiento y predicción. Se emplearán librerías como pandas, NumPy y scikit-learn para la manipulación y análisis de datos, junto con herramientas especializadas para la extracción automatizada como yfinance, feedparser y trafilatura. En etapas posteriores, se evaluará el uso de PyTorch o TensorFlow para incorporar modelos predictivos más avanzados, especialmente orientados al análisis de series temporales y texto.

Para la parte visual, se planea desarrollar una interfaz con TypeScript y React, que permita al usuario visualizar datos, tendencias y predicciones de manera intuitiva. Esta capa servirá como punto de interacción para explorar activos, revisar métricas y observar las señales generadas por los modelos.

El almacenamiento de la información se realizará en una base de datos PostgreSQL, debido a su robustez, compatibilidad con datos relacionales y capacidad de escalar hacia extensiones como TimescaleDB para manejar series temporales a futuro. Toda la infraestructura se ejecutará de forma local y contenida mediante Docker, lo que facilitará la replicabilidad, el aislamiento de entornos y la portabilidad del sistema entre equipos.

El control de versiones se gestionará con Git y GitHub, asegurando la trazabilidad del código y los experimentos, mientras que las prácticas de CI/CD se implementarán mediante GitHub Actions, para automatizar pruebas y despliegues futuros. Aunque en esta primera fase no se contempla el despliegue en nube ni un monitoreo activo, la arquitectura se diseña

considerando futuras integraciones con herramientas de orquestación y observabilidad, alineándose con las buenas prácticas de MLOps para facilitar la evolución del sistema hacia entornos productivos más complejos.

Análisis sobre datos

1. Fuentes, formatos y modelos

El sistema obtiene información desde fuentes heterogéneas que incluyen APIs financieras, feeds RSS, y scraping selectivo de noticias económicas u otras. Estas fuentes aportan datos tanto cuantitativos (precios, volumen, variaciones) como cualitativos (noticias, titulares, sentimiento del mercado). Los datos financieros se estructuran en formato tabular mediante librerías de Python como pandas, mientras que los textos se procesan en JSON, formatos que facilitan su almacenamiento y análisis eficiente.

El modelo de datos adoptado es relacional, integrando tablas de activos, precios, noticias y relaciones entre ambos. Esta estructura garantiza integridad referencial, facilita la trazabilidad entre fuentes y soporta la expansión hacia nuevos tipos de información, como redes sociales o reportes macroeconómicos.

2. Bases de Datos y Pipelines

Toda la información se almacena en PostgreSQL, elegido por su estabilidad, escalabilidad y soporte para consultas analíticas. En fases posteriores, puede ampliarse con TimescaleDB para optimizar el manejo de series temporales.

El procesamiento de datos se organiza en un pipeline automatizado que cubre las etapas de extracción, validación, limpieza, enriquecimiento y persistencia. Este pipeline se ejecuta mediante scripts en Python y contenedores Docker, lo que asegura reproducibilidad y aislamiento de entornos. Cada módulo es independiente (ingesta, transformación, análisis y predicción), cumpliendo con los principios de modularidad y mantenibilidad de MLOps.

3. Data Sampling/Generation, Etiquetado, Resolución de Problemas

El proceso de muestreo busca garantizar que los datos utilizados para el entrenamiento y validación del sistema sean representativos, consistentes en el tiempo y libres de sesgos. Para el análisis de los activos financieros, se implementará un enfoque de Weighted Sampling, asignando mayor peso a los eventos críticos como caídas abruptas del mercado, anuncios macroeconómicos o crisis corporativas sin alterar la secuencia temporal de los datos. Este método permite que el modelo aprenda patrones relevantes durante episodios de alta volatilidad, pero requiere especial cuidado para evitar sesgos o sobreajuste hacia regímenes extremos.

Entre los riesgos identificados se encuentran la posible pérdida de generalización en periodos de baja volatilidad, el data leakage si los pesos se calculan con información posterior al horizonte de predicción, y la reducción del tamaño muestral efectivo por sobre-muestrear ventanas temporales correlacionadas. Por ello, se aplicarán splits temporales estrictos (70% entrenamiento, 15% validación, 15% prueba) y técnicas de cross-validation temporal, asegurando la consistencia cronológica de los datos y evitando fugas de información.

En cuanto a las noticias financieras, también se utilizará Weighted Sampling para compensar el desbalance de clases (por ejemplo, predominio de noticias neutrales sobre positivas o negativas). Sin embargo, se cuidará que la redistribución de pesos no distorsione la realidad del mercado ni amplifique errores de etiquetado. Finalmente, se generarán características derivadas (como indicadores de volatilidad, retornos porcentuales o embeddings de texto) que complementen la información original y mejoren la capacidad predictiva del sistema.

4. Checks

Los checks y gates de calidad de datos garantizan que toda la información utilizada en el sistema sea confiable, coherente y apta para el análisis. Antes de ingresar al pipeline, los

datos financieros y textuales pasan por validaciones estructurales que detectan valores nulos, duplicados, inconsistencias temporales o errores de formato. Además, se aplican procesos de normalización y estandarización para unificar nombres, fechas, unidades y estructuras provenientes de distintas fuentes, asegurando que la base de datos mantenga integridad y compatibilidad entre conjuntos.

De igual forma, se incluyen controles semánticos que evalúan la relevancia y el contexto de las noticias, vinculándolas correctamente con los activos financieros a los que hacen referencia. Cada lote de datos validado se audita y versiona, registrando su origen y estado para permitir trazabilidad completa. En conjunto, estos mecanismos actúan como filtros que aseguran la calidad, confiabilidad y reproducibilidad del sistema, en línea con los principios de MLOps y las buenas prácticas de ingeniería de datos.